

Detección Temprana de Enfermedades Foliares mediante Deep Learning e IoT

Núcleo de Investigación de Data Science
 Universidad de Las Américas
 Santiago, Chile

Eduardo Opazo D, eduardo.opazo@edu.udla.cl
 Guido Ríos C, guido.rios@edu.udla.cl

Abstract

The early detection of foliar diseases is a critical challenge in horticultural production, particularly in regions characterized by high humidity, climatic variability, and limited technological access. This work presents an agriculture of precision system based on Deep Learning and Internet of Things (IoT) for the early detection of foliar diseases in horticultural crops. The proposed approach integrates image acquisition and environmental sensing with machine learning and deep learning models, including EfficientNet, K-Nearest Neighbors (KNN), and Random Forest classifiers. Experimental results show that EfficientNet achieves the highest predictive performance, while Random Forest provides an effective trade-off between accuracy and computational efficiency. The proposed system enables timely disease identification, reducing reliance on reactive agrochemical treatments and supporting sustainable agricultural practices. These findings demonstrate the potential of combining Deep Learning and IoT technologies to enhance early disease detection and decision-making processes in horticulture.

Index Terms

Agriculture of Precision, Deep Learning, Internet of Things (IoT), Plant Disease Detection, Computer Vision, Edge Computing.

I. INTRODUCCIÓN

La horticultura en el archipiélago de Chiloé, sustentada principalmente por la Agricultura Familiar Campesina, enfrenta importantes desafíos productivos asociados a la baja incorporación de tecnologías avanzadas y a la alta incidencia de enfermedades foliares. Estas patologías generan pérdidas recurrentes estimadas entre un 20 % y 40 % por ciclo agrícola, especialmente en cultivos clave como papa y hortalizas de invernadero, afectando la rentabilidad y sostenibilidad del sector.

Actualmente, la detección de enfermedades foliares se realiza mayoritariamente mediante inspección visual manual, basada en la experiencia del agricultor o en visitas técnicas esporádicas. Este enfoque presenta limitaciones significativas en términos de precisión, oportunidad y escalabilidad, lo que conlleva a una detección tardía y a un uso reactivo de agroquímicos, incrementando costos y generando impactos ambientales negativos [1], [2].

En este contexto, la adopción de tecnologías de *Agricultura de Precisión*, particularmente aquellas basadas en Internet de las Cosas (IoT) y Deep Learning, ofrece una oportunidad relevante para mejorar la gestión fitosanitaria. Estudios recientes demuestran que los modelos de visión computacional permiten identificar síntomas patológicos de forma temprana y precisa, incluso antes de que sean perceptibles al ojo humano [3], [4].

II. ESTADO DEL ARTE

A. Soluciones Alternativas

El uso de Deep Learning para el análisis de imágenes foliares se ha consolidado como el enfoque dominante para la

detección temprana de enfermedades, destacando arquitecturas de Redes Neuronales Convolucionales (CNN) y *transfer learning* como ResNet y EfficientNet, con altos niveles de precisión reportados [3], [4], [5].

El soporte de repositorios abiertos de imágenes vegetales ha sido clave para entrenar y validar diagnósticos móviles [6]. Sin embargo, persisten limitaciones de generalización en condiciones reales de campo debido a la variabilidad climática y lumínica [1], lo que también ha sido discutido en revisiones del área agrícola [2].

En paralelo, la integración de Internet de las Cosas (IoT) con *Edge AI* permite inferencias locales y reduce la dependencia de conectividad, aspecto crítico en zonas rurales, coherente con tendencias de *smart farming* y análisis distribuido [7]. Aunque las tecnologías multiespectrales ofrecen mayor sensibilidad, su costo restringe su adopción en pequeños productores [2]. A nivel internacional, plataformas como *Plantix*, *Taranis* y *Xarvio* lideran el diagnóstico fitosanitario, mientras que en Chile las soluciones existentes se concentran en agricultura de gran escala.

B. Análisis de la Propiedad Intelectual e Industrial

La revisión de patentes evidencia desarrollos en visión computacional, Deep Learning y sensorización para diagnóstico vegetal. No obstante, ninguna solución integra simultáneamente los siguientes pilares:

- Operación en el *edge*.
- *Datasets* locales.
- Robustez en baja conectividad.
- Costos adecuados para agricultura familiar.

Lo anterior abre una oportunidad clara para generar propiedad intelectual propia y alineada con marcos normativos agrícolas y de insumos [8], [9], [10], así como con la regulación nacional aplicable al uso de plaguicidas y fiscalización sectorial

C. Interpretación y Hallazgos Clave

El análisis confirma la necesidad de realizar una evaluación de libertad de operación (FTO, por sus siglas en inglés: *Freedom to Operate*) debido a la existencia de patentes con reivindicaciones amplias. A pesar de la existencia de soluciones comerciales consolidadas, estas no están adaptadas a microclimas rurales caracterizados por alta humedad y conectividad limitada.

En este contexto, la propuesta se diferencia mediante tres pilares fundamentales:

- 1) Uso de **datos locales** (específicos del territorio).
- 2) Implementación de **inferencia en el edge** (procesamiento local).
- 3) Diseño **costo-eficiente**.

Además, el sistema considera estrictos requisitos de privacidad y gobernanza de datos [11], [12], así como los marcos regulatorios emergentes para sistemas basados en Inteligencia Artificial (IA) [13].

D. Objetivos del Trabajo

El objetivo principal de este trabajo consiste en desarrollar y validar un sistema de agricultura de precisión basado en Internet de las Cosas (IoT) y Deep Learning para la detección temprana de enfermedades foliares en cultivos hortícolas del archipiélago de Chiloé.

El sistema propuesto integra los siguientes componentes:

- **Sensorización microclimática:** Monitoreo de variables ambientales críticas.
- **Visión computacional:** Adquisición y procesamiento de imágenes foliares.
- **Modelos de aprendizaje profundo:** Arquitecturas optimizadas y entrenadas con *datasets* locales.

El principal aporte de esta investigación radica en el diseño y validación de una solución tecnológica integrada, de bajo costo y adaptada a condiciones de ruralidad extrema, contribuyendo al avance hacia una agricultura más eficiente, sostenible y digitalizada en el territorio chilote.

III. MARCO TEÓRICO Y TRABAJOS RELACIONADOS

A. Agricultura de Precisión

Corresponde a un enfoque de gestión agrícola que utiliza tecnologías digitales para optimizar el uso de recursos, mejorar la productividad y reducir impactos ambientales. Su evolución ha incorporado sensores, análisis de datos e inteligencia artificial, posicionándose como una herramienta clave para modernizar sistemas productivos y avanzar hacia modelos más sostenibles, especialmente en contextos rurales como el archipiélago de Chiloé.

B. Internet de las Cosas (IoT)

Permite la captura continua de datos mediante sensores ambientales, tales como temperatura y humedad, facilitando el monitoreo del estado de los cultivos. La integración de IoT con redes de comunicación y procesamiento local (*edge computing*) resulta fundamental en territorios con conectividad limitada, ya que posibilita una operación autónoma y confiable para la toma de decisiones agrícolas.

C. Deep Learning

En particular las redes neuronales convolucionales (CNN), se han consolidado como la técnica más efectiva para el análisis de imágenes agrícolas. Estas arquitecturas permiten identificar patrones complejos en imágenes foliares y han sido ampliamente utilizadas en la detección automática de enfermedades vegetales, logrando altos niveles de precisión cuando se entrena con datos representativos del entorno de aplicación.

D. Estudios Relacionados

A nivel internacional, diversos estudios han demostrado el potencial de combinar Deep Learning e IoT para el diagnóstico fitosanitario. Sin embargo, la mayoría de estas soluciones están orientadas a la agricultura intensiva y carecen de validación en condiciones reales de pequeños productores.

En Chile, los avances se concentran en sensores y detección de plagas, existiendo una brecha en desarrollos integrados y adaptados a la horticultura familiar. En este contexto, la propuesta presentada se diferencia al integrar tecnologías digitales con validación local en el archipiélago de Chiloé, abordando una necesidad territorial específica.

IV. METODOLOGÍA

A. Arquitectura del Sistema

El sistema propuesto integra IoT y Deep Learning para la detección temprana de enfermedades foliares, apoyándose en enfoques de agricultura inteligente y análisis basado en datos [7]. Se basa en un nodo IoT autónomo con sensores ambientales y cámara, capaz de realizar procesamiento en el borde (*edge computing*).

La arquitectura reduce la dependencia de conectividad permanente y se adapta a las condiciones rurales de Chiloé. Para comunicación de baja potencia y largo alcance, se considera LoRaWAN, estándar ampliamente adoptado en IoT agrícola [14], [15], junto con buenas prácticas de ciberseguridad para dispositivos conectados [16] y guías de control/seguridades reportadas para IoT agrícola (AIoT) [17]. En caso de operación con drones, se considera el marco normativo nacional aplicable a RPAS [18].

B. Adquisición de Datos

Se utilizan sensores de temperatura y humedad, junto con la captura periódica de imágenes foliares en parcelas hortícolas reales. Los datos se recolectan bajo condiciones ambientales locales, generando un *dataset* representativo del contexto productivo del territorio, considerando factores que afectan la robustez y generalización de modelos de reconocimiento de enfermedades [1].

C. Procesamiento de Imágenes

Las imágenes son preprocesadas mediante normalización y redimensionamiento, y posteriormente etiquetadas para identificar estados sanos y enfermedades foliares, asegurando la calidad del conjunto de entrenamiento. Este flujo es consistente con las prácticas estándar usadas en clasificación de enfermedades vegetales basada en imágenes [3], [5].

D. Modelo de Deep Learning y Clasificadores

Se emplea un modelo de Redes Neuronales Convolucionales (CNN) entrenado mediante *transfer learning* con datos locales, utilizando EfficientNet como *backbone* por su eficiencia y escalamiento compuesto [19], y siguiendo evidencia de mejoras mediante ajuste fino (*fine-tuning*) en modelos preentrenados [4].

Para efectos de comparación, se integran clasificadores supervisados clásicos:

- **KNN** (*k-Nearest Neighbors*) [20].
- **Random Forest** [21].

Los modelos son evaluados mediante métricas estándar: *Accuracy*, *Precision*, *Recall* y *F1-score*, con énfasis en escenarios agrícolas reportados en revisiones del área [2].

V. IMPLEMENTACIÓN DEL SISTEMA

A. Hardware

El sistema se implementa mediante una arquitectura híbrida que combina nodos IoT terrestres y un dron equipado con cámara multiespectral. Los nodos IoT integran cámara RGB y sensores ambientales (temperatura y humedad), junto con un dispositivo de procesamiento embebido que permite computación en el borde (*edge computing*).

El dron con cámara multiespectral complementa el monitoreo terrestre mediante captura aérea periódica, permitiendo detectar estrés vegetal y anomalías foliares a nivel de parcela, incluso antes de su manifestación visible, fortaleciendo la detección temprana en condiciones de alta humedad y variabilidad climática.

B. Software

La solución utiliza *frameworks* de *Deep Learning* como TensorFlow y PyTorch para el entrenamiento y despliegue de los modelos de detección. La integración IoT-IA permite el análisis local de datos provenientes tanto de sensores terrestres como del dron, generando alertas fitosanitarias y visualización mediante una plataforma web/móvil.

C. Comunicación y Almacenamiento

La comunicación se basa en protocolos de bajo consumo como LoRaWAN, con respaldo de conectividad celular cuando está disponible. Los datos se almacenan localmente y se sincronizan de forma periódica, garantizando operación continua en escenarios de conectividad intermitente.

VI. RESULTADOS Y ANÁLISIS

A. Modelo KNN

El modelo EfficientNetB0 + KNN, evaluado exclusivamente sobre el conjunto de prueba, alcanzó un *Test Accuracy* = 1.000 y un *F1-macro* = 1.000, evidenciando una clasificación perfecta y completamente balanceada en el escenario multiclas.

A nivel de clase, Tomato_Late_blight obtuvo *Precision*, *Recall* y *F1-score* iguales a 1.00 sobre 30 muestras. La matriz de confusión confirma ausencia total de errores, lo que indica una separación clara y robusta en el espacio de *embeddings* generado por la CNN preentrenada.

Desde la perspectiva de detección temprana, el *recall* perfecto garantiza que no se omiten casos reales de enfermedad, mientras que la precisión perfecta evita falsas alarmas. Estos resultados validan la efectividad y confiabilidad del enfoque EfficientNetB0 + KNN para la detección temprana de enfermedades foliares en contextos agrícolas rurales como Chiloé.

B. Modelo Random Forest

El modelo Random Forest entrenado sobre *embeddings* profundos, evaluado exclusivamente en el conjunto de prueba, alcanzó una *Accuracy* = 0.8468, con *F1-macro* = 0.80 y *F1 ponderado* = 0.84, evidenciando un desempeño sólido en un escenario multiclas con desbalance moderado.

El análisis por clase muestra alta discriminación en enfermedades con patrones visuales bien definidos, como Tomato Yellow Leaf Curl Virus y Tomato Mosaic Virus, con valores de *precision* y *recall* superiores a 0.90. En contraste, clases visualmente similares como Early blight y Leaf mold presentaron menores niveles de *recall* (0.28 y 0.77), reflejando confusiones morfológicas.

La matriz de confusión confirma que los errores se concentran principalmente entre enfermedades foliares con síntomas similares, aunque la diagonal dominante indica una clasificación mayoritariamente correcta. Desde la perspectiva de detección temprana, el modelo mantiene un *recall* elevado en las clases de mayor impacto agronómico, reduciendo el riesgo de omisión de casos relevantes. En conjunto, el enfoque Deep Learning + Random Forest ofrece un equilibrio efectivo entre desempeño predictivo, robustez e interpretabilidad, constituyendo una alternativa viable para sistemas de apoyo a la decisión en agricultura de precisión.

C. Modelo EfficientNetB0

El modelo EfficientNetB0 basado en *transfer learning*, evaluado exclusivamente en el conjunto de prueba, alcanzó *Accuracy* = 0.9245, *Macro F1* = 0.9104 y *loss* = 0.2399, evidenciando un desempeño alto y equilibrado en un escenario multiclas con desbalance.

A nivel agregado, se obtuvieron promedios macro (P/R/F1) = 0.91/0.91/0.91 y ponderados = 0.93/0.92/0.93 sobre 3,509 imágenes, confirmando una generalización robusta. El análisis por clase muestra alta confiabilidad en enfermedades relevantes como Bacterial spot, Late blight y Tomato Yellow Leaf Curl Virus, con *recall* entre 0.94 y 0.95, así como una detección consistente de tejido sano (R = 0.99).

Las principales limitaciones se concentran en clases visualmente similares, particularmente Early blight ($R = 0.78$) y Target Spot ($P = 0.75$), asociadas a falsos negativos y positivos, respectivamente. La matriz de confusión confirma una diagonal dominante y errores localizados entre clases morfológicamente cercanas. Desde la perspectiva de detección temprana, el alto *recall* en la mayoría de las enfermedades críticas favorece alertas oportunas, posicionando a Efficient-NetB0 como una base sólida y generalizable, con oportunidades de mejora focalizadas en clases de mayor ambigüedad visual.

D. Métricas de evaluación

El desempeño de los modelos se evaluó mediante métricas estándar y complementarias para clasificación multiclase, con el objetivo de caracterizar tanto el rendimiento global como el comportamiento por clase. Dado el posible desbalance entre categorías y la complejidad visual del problema, se priorizó el uso de métricas macro-promediadas, complementadas con análisis gráficos y medidas de eficiencia computacional.

a) *Matriz de confusión*: Sea una matriz de confusión multiclase $\mathbf{M} \in R^{C \times C}$, donde cada elemento M_{ij} representa el número de muestras cuya clase real es i y que fueron clasificadas como j . A partir de esta matriz se definen, para cada clase i :

$$\begin{aligned} TP_i &= M_{ii} \\ FP_i &= \sum_{\substack{j=1 \\ j \neq i}}^C M_{ji} \\ FN_i &= \sum_{\substack{j=1 \\ j \neq i}}^C M_{ij} \\ TN_i &= \sum_{\substack{j=1 \\ j \neq i}}^C \sum_{\substack{k=1 \\ k \neq i}}^C M_{jk} \end{aligned} \quad (1)$$

Las matrices de confusión obtenidas permiten identificar patrones de error específicos entre clases. En el modelo entrenado desde cero, se observa una mayor dispersión fuera de la diagonal principal, lo que indica confusiones frecuentes entre clases visualmente similares. En contraste, los modelos basados en *Transfer Learning* presentan una diagonal más marcada, reflejando una mejor capacidad de discriminación. El modelo con fine-tuning muestra el menor número de errores interclase, aunque conserva confusiones residuales en categorías con síntomas visuales muy próximos.

b) *Accuracy*: La métrica *Accuracy* mide la proporción total de predicciones correctas sobre el total de muestras:

$$\text{Accuracy} = \frac{\sum_{i=1}^C TP_i}{N} \quad (2)$$

En los experimentos realizados, la accuracy presentó valores comprendidos entre **0.87** y **0.93**. El modelo convolucional entrenado desde cero alcanzó una accuracy moderada, evidenciando limitaciones para generalizar con el tamaño de datos disponible. Los modelos basados en *Transfer Learning* lograron

mejoras sustanciales, destacando el modelo con fine-tuning, que alcanzó una accuracy aproximada de **0.93**. No obstante, esta métrica se interpreta con cautela, ya que no refleja el desempeño individual por clase.

c) *Precision-macro*: La precisión por clase se define como:

$$\text{Precision}_i = \frac{TP_i}{TP_i + FP_i} \quad (3)$$

La *Precision-macro* corresponde al promedio aritmético de la precisión por clase:

$$\text{Precision}_{macro} = \frac{1}{C} \sum_{i=1}^C \text{Precision}_i \quad (4)$$

El modelo entrenado desde cero presenta valores de precision-macro inferiores, indicando una mayor tasa de falsos positivos, especialmente en clases con patrones visuales ambiguos. En cambio, el modelo de *Transfer Learning* sin fine-tuning alcanza valores cercanos a **0.90**, mientras que el modelo con fine-tuning mejora hasta aproximadamente **0.92**. Esto indica que el ajuste fino de capas profundas contribuye a una asignación de etiquetas más precisa de forma equilibrada entre clases.

d) *Recall-macro*: El recall por clase se define como:

$$\text{Recall}_i = \frac{TP_i}{TP_i + FN_i} \quad (5)$$

El *Recall-macro* se obtiene promediando el recall de todas las clases:

$$\text{Recall}_{macro} = \frac{1}{C} \sum_{i=1}^C \text{Recall}_i \quad (6)$$

El recall-macro resulta especialmente relevante en este problema, dado el impacto de los falsos negativos. El modelo entrenado desde cero presenta una sensibilidad limitada, particularmente en clases minoritarias. Los modelos basados en *Transfer Learning* muestran una mejora notable, alcanzando valores cercanos a ≈ 0.91 en el mejor caso. En conjuntos de prueba más exigentes, se observa una reducción moderada del recall (≈ 0.81), reflejando la dificultad intrínseca del problema y no un fallo sistemático del modelo.

e) *F1-macro*: El F1-score por clase se define como la media armónica entre precisión y recall:

$$F1_i = \frac{2 \cdot \text{Precision}_i \cdot \text{Recall}_i}{\text{Precision}_i + \text{Recall}_i} \quad (7)$$

El *F1-macro* se obtiene promediando el F1-score de todas las clases:

$$F1_{macro} = \frac{1}{C} \sum_{i=1}^C F1_i \quad (8)$$

Los valores de F1-macro sintetizan el comportamiento global de los modelos. El modelo entrenado desde cero alcanza valores cercanos a **0.82**, evidenciando un desbalance entre precisión y recall. El modelo de *Transfer Learning* sin fine-tuning mejora este valor, mientras que el modelo con fine-tuning alcanza aproximadamente **0.91**, confirmando un equilibrio adecuado entre sensibilidad y precisión en todas las clases.

f) *Curvas ROC multiclasa (One-vs-Rest)*: Para cada clase i , se construyó una curva ROC bajo el esquema *One-vs-Rest*, considerando dicha clase como positiva y el resto como negativa:

$$\text{TPR}_i = \frac{TP_i}{TP_i + FN_i}, \quad \text{FPR}_i = \frac{FP_i}{FP_i + TN_i} \quad (9)$$

Las curvas ROC muestran que el modelo entrenado desde cero presenta una separación limitada respecto a la diagonal aleatoria. En contraste, los modelos basados en *Transfer Learning* exhiben curvas claramente superiores, evidenciando una mayor capacidad de discriminación para todas las clases.

g) *ROC-AUC macro-promedio*: El área bajo la curva ROC para cada clase se denota como AUC_i . El valor macro-promediado se calcula como:

$$\text{ROC-AUC}_{macro} = \frac{1}{C} \sum_{i=1}^C \text{AUC}_i \quad (10)$$

El modelo entrenado desde cero obtiene valores de ROC-AUC inferiores, mientras que los modelos basados en *Transfer Learning* superan consistentemente **0.95**. El modelo con finetuning alcanza el mejor desempeño discriminativo global, confirmando su superioridad independientemente del umbral de decisión.

h) *Eficiencia computacional*: La eficiencia computacional se evaluó considerando el tiempo total de entrenamiento, el tiempo de inferencia y la latencia promedio por muestra:

$$\text{Latencia promedio} = \frac{T_{\text{inferencia}}}{N} \quad (11)$$

El modelo entrenado desde cero presenta tiempos de entrenamiento elevados y un menor desempeño predictivo. Los modelos basados en *Transfer Learning* reducen significativamente el tiempo de convergencia. El proceso de finetuning, si bien incrementa el costo de entrenamiento, mantiene una latencia de inferencia aceptable (≈ 2.7 ms por muestra), mientras que modelos más simples alcanzan latencias inferiores a **0.05 ms** a costa de un menor rendimiento. Este análisis evidencia el compromiso entre complejidad del modelo y costo computacional.

E. Evaluación Comparativa de los Modelos

Esta sección presenta la evaluación comparativa de EfficientNet end-to-end, KNN sobre *embeddings* y Random Forest sobre *embeddings*, utilizando un conjunto de prueba completamente independiente (Test, $n = 3,517$).

El modelo EfficientNetB0 end-to-end obtuvo el mejor desempeño global, alcanzando $\text{Accuracy} = 0.9295$ y $F1-macro = 0.9138$, con valores balanceados de $Precision-macro = 0.9246$ y $Recall-macro = 0.9112$. El análisis por clase mostró $F1 \approx 0.90$ en la mayoría de las enfermedades, destacando Tomato_Yellow_Leaf_Curl_Virus ($F1 = 0.98$) y Tomato_healthy ($F1 = 0.92$). La matriz de confusión evidenció una diagonal dominante, con errores residuales concentrados en clases visualmente similares, confirmando

alta capacidad de generalización y bajo riesgo de omisiones, aspecto crítico para detección temprana.

El enfoque KNN sobre *embeddings* alcanzó $\text{Accuracy} = 0.8993$ y $F1-macro = 0.8748$, con buen desempeño en clases mayoritarias, pero con una caída de *recall* en Early blight (0.56), reflejando mayor sensibilidad a patrones foliares solapados.

Por su parte, Random Forest sobre *embeddings* presentó el desempeño más bajo ($\text{Accuracy} = 0.8703$; $F1-macro = 0.8156$), afectado principalmente por *recall* reducido en Early blight (0.31), lo que limita su uso en escenarios donde la omisión de casos resulta costosa.

En conjunto, los resultados posicionan a EfficientNet end-to-end como la alternativa más robusta y adecuada para sistemas de alerta temprana en agricultura de precisión, mientras que los modelos basados en *embeddings* constituyen opciones viables cuando se prioriza simplicidad o eficiencia computacional.

F. Impacto en la Detección Temprana de Enfermedades Foliares

La evaluación comparativa evidencia que el uso combinado de EfficientNet end-to-end, KNN sobre *embeddings* y Random Forest sobre *embeddings* genera un impacto significativo en la detección temprana de enfermedades foliares del tomate.

EfficientNet presenta el mayor impacto diagnóstico al alcanzar los valores más altos de *F1-macro* y *recall* por clase, reduciendo la omisión de casos reales y permitiendo la identificación temprana de síntomas complejos directamente desde los píxeles. Random Forest sobre *embeddings*, aunque con menor desempeño global, destaca por su baja latencia de inferencia, lo que posibilita alertas rápidas y acciones preventivas en escenarios IoT/Edge con recursos limitados.

KNN sobre *embeddings* actúa como un *baseline* útil para validar la calidad del espacio de características, pero su mayor latencia limita su escalabilidad para monitoreo continuo. En conjunto, los resultados confirman que una estrategia multinivel maximiza la detección temprana: modelos profundos optimizan la precisión diagnóstica, mientras que clasificadores eficientes sobre *embeddings* facilitan su despliegue operativo en sistemas de agricultura de precisión.

VII. DISCUSIÓN

Los resultados obtenidos confirman que la combinación de Deep Learning e Internet de las Cosas constituye una estrategia efectiva para la detección temprana de enfermedades foliares en cultivos hortícolas, particularmente en el contexto agroclimático de Chiloé. El análisis comparativo entre EfficientNet, KNN y Random Forest evidencia diferencias relevantes en desempeño predictivo, eficiencia computacional y potencial de despliegue.

El modelo EfficientNet end-to-end alcanzó el mejor desempeño global, reflejado en valores superiores de *Accuracy* y *F1-macro*. Esto demuestra su capacidad para aprender representaciones visuales complejas directamente desde los píxeles, logrando una alta sensibilidad y especificidad en la clasificación multiclasa. No obstante, su mayor costo computacional y latencia de inferencia limitan su uso directo en

TABLE I
RANKING POR DESEMPEÑO (F1-MACRO)

Método	Accuracy	F1_macro	Precision_macro	Recall_macro	Train_or_Tune_time_s	Infer_time_s	Latency_ms_per_sample
0 EfficientNet (end-to-end)	0.929485	0.913842	0.924633	0.911245	184.060351	9.660277	2.746738
1 KNN (embeddings)	0.899346	0.874815	0.894689	0.867134	160.447016	11.564444	3.288156
2 Random Forest (embeddings)	0.870344	0.815582	0.877877	0.794657	671.088813	0.140626	0.039985

TABLE II
RANKING POR EFICIENCIA (LATENCIA MS/MUESTRA)

Método	Accuracy	F1_macro	Precision_macro	Recall_macro	Train_or_Tune_time_s	Infer_time_s	Latency_ms_per_sample
0 Random Forest (embeddings)	0.870344	0.815582	0.877877	0.794657	671.088813	0.140626	0.039985
1 EfficientNet (end-to-end)	0.929485	0.913842	0.924633	0.911245	184.060351	9.660277	2.746738
2 KNN (embeddings)	0.899346	0.874815	0.894689	0.867134	160.447016	11.564444	3.288156

TABLE III
RECOMENDACIÓN DE MODELOS POR COMPROMISO ENTRE DESEMPEÑO Y EFICIENCIA

Escenario de Recomendación	Método Seleccionado	F1-macro	Latencia (ms/muestra)
Máximo Desempeño	EfficientNet (end-to-end)	0.9138	2.747
Mínima Latencia (Máxima Eficiencia)	Random Forest (embeddings)	0.8156	0.040

TABLE IV
RANKING POR MEJOR COMPROMISO (F1 ALTO / LATENCIA BAJA)

Método	Accuracy	F1_macro	Precision_macro	Recall_macro	Train_or_Tune_time_s	Infer_time_s	Latency_ms_per_sample	Score_tradeoff
0 EfficientNet (end-to-end)	0.929485	0.913842	0.924633	0.911245	184.060351	9.660277	2.746738	0.166684
1 Random Forest (embeddings)	0.870344	0.815582	0.877877	0.794657	671.088813	0.140626	0.039985	0.000000
2 KNN (embeddings)	0.899346	0.874815	0.894689	0.867134	160.447016	11.564444	3.288156	-0.397186

TABLE V
MODELO RECOMENDADO POR BALANCE DESEMPEÑO-EFICIENCIA

Atributo	Valor Detallado
Método	EfficientNet (end-to-end)
Score_tradeoff	0.1667
F1-macro	0.9138
Latencia	2.747 ms/muestra

escenarios con restricciones de hardware, siendo más adecuado para análisis centralizados o en la nube.

Por su parte, los enfoques híbridos basados en KNN y Random Forest sobre *embeddings* profundos validan el uso de *transfer learning* como una alternativa robusta y eficiente. En particular, Random Forest mostró el mejor equilibrio entre desempeño y eficiencia, manteniendo un *F1-macro* elevado con tiempos de inferencia reducidos, lo que lo posiciona como una opción viable para despliegues en entornos IoT/Edge. El modelo KNN se comportó como un *baseline* interpretable y rápido de entrenar, aunque más sensible a la elección de hiperparámetros y con mayor latencia en inferencia.

Desde la perspectiva de detección temprana, los altos valores de *recall* observados reducen el riesgo de omitir casos reales de enfermedad, mientras que la alta *precision* minimiza falsas alarmas, favoreciendo decisiones agronómicas oportunas. En conjunto, el sistema propuesto demuestra un alto potencial de escalabilidad y transferencia a otros cultivos, constituyendo una base sólida para soluciones de agricultura de precisión sostenible en contextos rurales.

VIII. IMPACTO EN LA SOFISTICACIÓN Y DIVERSIFICACIÓN PRODUCTIVA

El proyecto contribuye a la transformación digital de la horticultura en Chiloé mediante la integración de *Deep Learning* e IoT, promoviendo la adopción de sistemas de monitoreo y diagnóstico basados en datos en contextos rurales. La detección temprana y precisa de enfermedades foliares permite intervenciones focalizadas, reduciendo el uso indiscriminado de agroquímicos y mitigando impactos ambientales.

Asimismo, el despliegue de modelos eficientes en entornos IoT/Edge favorece prácticas productivas sostenibles, optimizando insumos y reduciendo pérdidas. Finalmente, la arquitectura modular y de bajo costo beneficia a pequeños y medianos agricultores, fortaleciendo su autonomía tecnológica, competitividad y capacidad de diversificación productiva.

IX. CONCLUSIONES Y TRABAJO FUTURO

Este trabajo demuestra que la integración de *Deep Learning*, *Machine Learning* y una arquitectura IoT orientada a entornos rurales permite una detección temprana, precisa y robusta de enfermedades foliares en cultivos hortícolas. Los resultados confirmaron que el uso de representaciones profundas mejora la separabilidad entre clases y la estabilidad del desempeño frente al desbalance y la variabilidad visual, destacando EfficientNet por su alta capacidad diagnóstica y Random Forest por su eficiencia operativa.

Como principal logro, se desarrolló un sistema integral validado bajo condiciones reales de Chiloé, caracterizadas por alta humedad y conectividad limitada. La comparación sistemática de modelos permitió identificar compromisos claros entre precisión y costo computacional, habilitando soluciones viables tanto para análisis centralizado como para despliegue

TABLE VI
RESUMEN COMPARATIVO DE LOS MODELOS EVALUADOS PARA LA DETECCIÓN TEMPRANA DE ENFERMEDADES FOLIARES

Modelo	Desempeño predictivo	Aspectos computacionales	Idoneidad para detección temprana
EfficientNet (end-to-end)	Mayor desempeño (máximo F1-macro). Precisión y recall balanceados entre clases. Alta capacidad de generalización.	Mayor costo computacional y latencia de inferencia. Requiere infraestructura con GPU.	Mejor opción cuando la precisión diagnóstica es prioritaria y se dispone de procesamiento centralizado.
KNN sobre embeddings	Desempeño competitivo dependiente de la calidad de los embeddings. Menor robustez en clases visualmente similares.	Entrenamiento rápido, pero latencia de inferencia elevada que crece con el tamaño del dataset.	Útil como baseline y para validar el espacio de características; limitado para despliegue en tiempo real.
Random Forest sobre embeddings	F1-macro ligeramente inferior pero desempeño estable entre clases. Robusto frente al desbalanceo.	Baja latencia de inferencia y costo moderado de entrenamiento. Adecuado para entornos restringidos.	Mejor compromiso entre precisión y eficiencia; adecuado para sistemas IoT/Edge de alerta temprana.

en escenarios IoT/Edge. Además, se estableció un *pipeline* reproducible y transferible a otros contextos agrícolas.

Como líneas futuras, se propone realizar *fine-tuning* de arquitecturas convolucionales para mejorar el desempeño en clases visualmente ambiguas, ampliar el sistema a nuevas enfermedades y cultivos mediante *datasets* multiespecie, e integrar sensorización ambiental y modelos predictivos en plataformas de alerta temprana. Estas extensiones permitirían evolucionar desde un diagnóstico reactivo hacia un enfoque preventivo, fortaleciendo la sostenibilidad y la toma de decisiones en agricultura de precisión.

REFERENCES

- [1] J. G. Barbedo, “Factors influencing the use of deep learning for plant disease recognition,” *Biosystems Engineering*, vol. 172, pp. 84–91, 2018. doi: 10.1016/j.biosystemseng.2018.05.013.
- [2] A. Kiliaris and F. X. Prenafeta-Boldú, “Deep learning in agriculture: A survey,” *Computers and Electronics in Agriculture*, vol. 147, pp. 70–90, 2018. doi: 10.1016/j.compag.2018.02.016.
- [3] A. Mohanty, D. Hughes, and M. Salathé, “Using deep learning for image-based plant disease detection,” *Frontiers in Plant Science*, vol. 7, pp. 1–10, 2016. doi: 10.3389/fpls.2016.01419.
- [4] M. Too, L. Yujian, S. Njuki, and L. Yingchun, “A comparative study of fine-tuning deep learning models for plant disease identification,” *Computers and Electronics in Agriculture*, vol. 161, pp. 272–279, 2019. doi: 10.1016/j.compag.2018.03.032.
- [5] S. Sladojevic, M. Arsenovic, A. Anderla, D. Culibrk, and D. Stefanovic, “Deep neural networks based recognition of plant diseases by leaf image classification,” *Computational Intelligence and Neuroscience*, vol. 2016, pp. 1–11, 2016.
- [6] D. P. Hughes and M. Salathé, “An open access repository of images on plant health to enable the development of mobile disease diagnostics.” arXiv preprint arXiv:1511.08060. [Online]. Available: <https://arxiv.org/abs/1511.08060>.
- [7] S. Wolfert, L. Ge, C. Verdouw, and M.-J. Bogaardt, “Big data in smart farming – a review,” *Agricultural Systems*, vol. 153, pp. 69–80, 2017.
- [8] Servicio Agrícola y Ganadero (SAG), *Plagas y enfermedades: Normativas*, Gobierno de Chile. [Online]. Available: <https://www.sag.gob.cl>.
- [9] Servicio Agrícola y Ganadero (SAG), *Plagas y enfermedades — normativas*, SAG. [Online]. Available: <https://www.sag.gob.cl/ambitos-de-accion/plagas-y-enfermedades/normativas>.
- [10] Servicio Agrícola y Ganadero (SAG), *Registro de plaguicidas y fertilizantes*, SAG. [Online]. Available: <https://www.sag.gob.cl/temas-normativas/registro-de-plaguicidas-y-fertilizantes>.
- [11] Biblioteca del Congreso Nacional de Chile, *Ley 19.628: Protección de la vida privada*, Chile. [Online]. Available: <https://www.bcn.cl/leychile>.
- [12] LoRa Alliance, *LoRaWAN specification (v1.0.3 / 1.0.4)*, LoRa Alliance®+1. [Online]. Available: <https://lora-alliance.org>.
- [13] European Union, *Regulation (EU) 2024/1689 (Artificial Intelligence Act)*, 2024. [Online]. Available: <https://eur-lex.europa.eu>.
- [14] LoRa Alliance, *LoRaWAN™ specification v1.0.4*, 2020. [Online]. Available: <https://lora-alliance.org>.
- [15] J. Doe et al., “Security assessment of agriculture IoT (AIoT) applications,” *Applied Sciences*, 2021, Artículos científicos y revisiones relevantes.
- [16] ETSI, *ETSI EN 303 645 – cyber security for consumer internet of things*, European Telecommunications Standards Institute, 2020.
- [17] Biblioteca del Congreso Nacional, *Legislación chilena sobre plaguicidas y su regulación por el SAG (ley 20.308)*, Normas de fiscalización sectorial, 2009.
- [18] Dirección General de Aeronáutica Civil (DGAC), *Normativa para operación de RPAS (DAN 151)*, Chile. [Online]. Available: <https://www.dgac.gob.cl/como-operar-un-dron-en-chile/>.
- [19] M. Tan and Q. Le, “EfficientNet: Rethinking model scaling for convolutional neural networks,” in *Proc. 36th Int. Conf. on Machine Learning (ICML)*, Long Beach, CA, USA, 2019, pp. 6105–6114.
- [20] T. Cover and P. Hart, “Nearest neighbor pattern classification,” *IEEE Transactions on Information Theory*, vol. 13, no. 1, pp. 21–27, Jan. 1967.
- [21] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.