

## mediante Deep Learning e IoT



# “Detección Temprana de Enfermedades Foliares mediante Deep Learning e IoT”

Agricultura de Precisión

**Eduardo Opazo D. Guido Ríos C.**

Núcleo Data Science, Facultad de Ingeniería y Negocios Universidad de las Américas



# Introducción y Contexto

- **Contexto crítico en Chiloé:** alta humedad, lluvias frecuentes y variabilidad térmica favorecen enfermedades foliares en papa y tomate.
- **Impacto productivo:** pérdidas de hasta 40% y uso intensivo de agroquímicos.
- **Limitación actual:** detección tardía basada en inspección visual manual.
- **Propuesta:** sistema automatizado de **detección temprana** mediante **Deep Learning + IoT**.
- **Beneficios:** alertas predictivas, mejor toma de decisiones, **reducción de agroquímicos** y mayor **productividad y sostenibilidad**.



**Enfermedad Foliar de la Papa en Chiloé**

# Problema y Motivación

- **Problema crítico:** las *enfermedades foliares reducen la productividad* y afectan la sostenibilidad económica y ambiental de pequeños y medianos productores.
- **Limitación actual:** *detección tardía basada en inspección visual* y decisiones reactivas.
- **Solución tecnológica:** *Visión Computacional + Deep Learning + IoT* permiten detección temprana y monitoreo continuo, incluso antes de la percepción humana.

# Problema y Motivación

- **Impacto esperado:** *mejor toma de decisiones agronómicas, mayor rendimiento, menor uso de insumos químicos.*
- **Proyección:** impulso a la **Agricultura de Precisión 4.0** adaptada a las condiciones de Chiloé, *fortaleciendo la sostenibilidad productiva y ambiental.*



**Detección Temprana de Enfermedades Foliares mediante Drones o Tablet**

# Metodología Propuesta

- **Sistema de Agricultura de Precisión que integra Visión Computacional, Deep Learning e IoT para la detección temprana de enfermedades foliares.**
- **Monitoreo automatizado y continuo, mediante sensores microclimáticos y cámaras conectadas por LoRaWAN/4G, entrenado con datos locales de Chiloé.**
- **Alertas tempranas y visualización simple en plataformas web y móviles, apoyando decisiones fitosanitarias oportunas.**

# Metodología Propuesta

- **Impacto:** reducción de pérdidas productivas, optimización del uso de agroquímicos y beneficio directo a pequeños agricultores.
- **Proyección:** desarrollo de un **prototipo validado**, con potencial de **escalamiento y transferencia** al sector productivo regional.

# **Esquema Conceptual de la Solución**

# Detección Temprana de Enfermedades Foliares mediante Deep Learning e IoT



# Esquema Conceptual de la Solución

- **Componentes tecnológicos protegibles:** Integración de hardware, software y modelos de IA propios que aseguran diferenciación y ventaja competitiva.
- **Tecnologías open-source validadas:** Uso de soluciones abiertas consolidadas que garantizan flexibilidad, seguridad jurídica y escalabilidad comercial.
- **Estrategia de PI y licenciamiento:** Desarrollo propio con hardware abierto y registro de software, evitando restricciones y dependencias de terceros.
- **Impacto en transferencia tecnológica:** Arquitectura orientada a facilitar la validación del prototipo y su adopción por el sector productivo.



Trips occidental



Mosca blanca



Pulgones

Plagas de insectos afectando el cultivo de papa en Chiloé



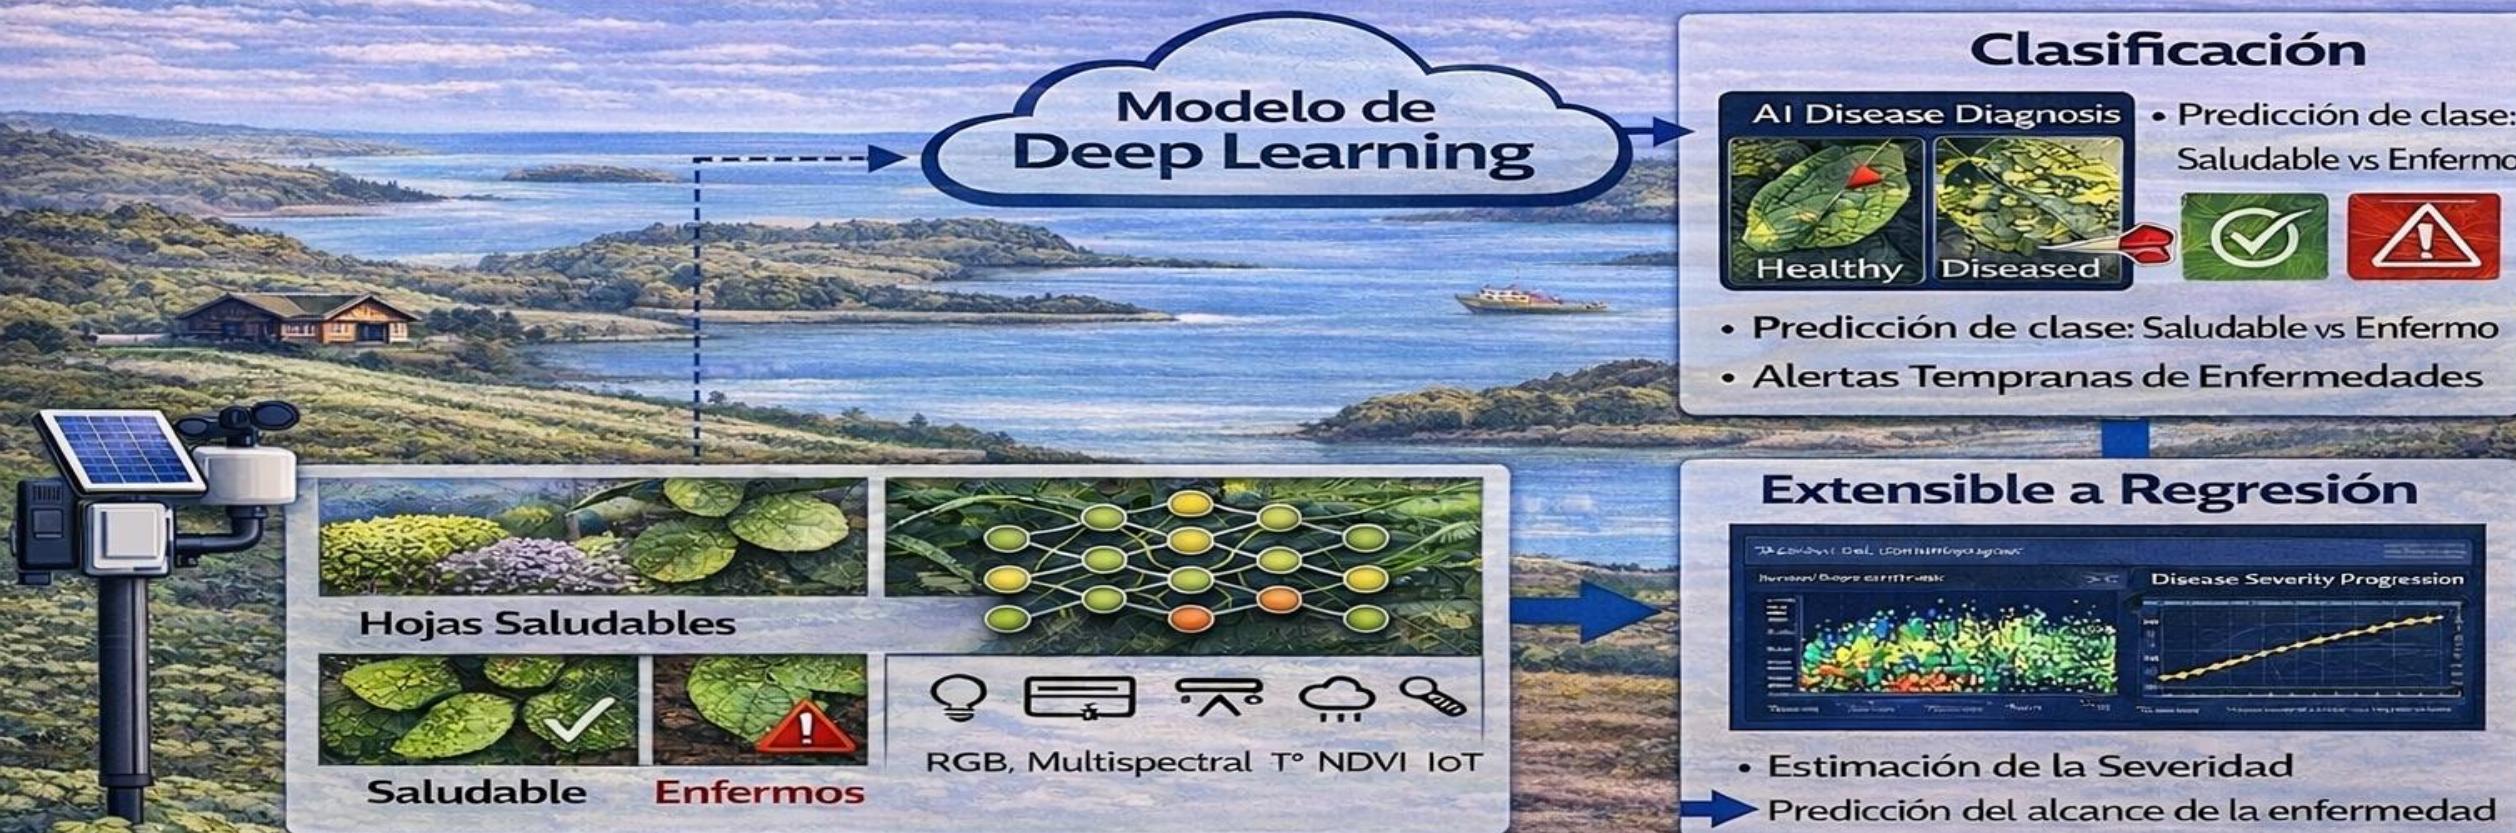
# Uso de Imágenes Multiespectrales

- **Limitación actual:** la inspección visual detecta enfermedades en etapas tardías y con alta subjetividad.
- **Ventaja multiespectral:** el estrés vegetal altera la **reflectancia espectral** antes de ser visible al ojo humano, especialmente relevante en el clima de Chiloé.
- **Datos clave:** uso de **RGB, Red Edge y NIR**, junto a índices **NDVI, GNDVI** y **NDRE**, para detectar cambios tempranos en vigor y clorofila.

# Uso de Imágenes Multiespectrales

- **Integración inteligente:** imágenes + variables ambientales mediante IA e IoT, generando **mapas de salud del cultivo**.
- **Impacto:** detección temprana, decisiones agrícolas más precisas y **Agricultura de Precisión sostenible** en Chiloé.

# Detección Temprana de Enfermedades Foliares mediante Deep Learning e IoT



# Enfoque de Aprendizaje Supervisado

- **Problema de clasificación supervisada:** identificación automática del estado sanitario de hojas hortícolas en Chiloé.
- **Datos de entrada:** imágenes foliares y **variables ambientales IoT**, capturadas en condiciones reales de campo.
- **Modelos Deep Learning:** **redes neuronales convolucionales (CNN)** entrenadas para detectar enfermedades específicas.
- **Evaluación y extensión:** métricas estándar de clasificación y  **posible extensión a regresión de severidad.**
- **Impacto:** apoyo a **decisiones agronómicas tempranas y transferencia tecnológica.**

# Enfoque de Aprendizaje Supervisado

- Por tanto, el proyecto “**Hacia una Agricultura de Precisión en Chiloé: Sistema Basado en Deep Learning e IoT para la Detección Temprana de Enfermedades Foliares en Cultivos Hortícolas**”
- Se va a modelar como un **problema de aprendizaje supervisado de clasificación**, con posibilidad de extensión a **regresión para estimar severidad**.

# Detección Temprana de Enfermedades Foliares mediante Deep Learning e IoT



# Detección Temprana de Enfermedades Foliares mediante Deep Learning e IoT

## Justificación del Desafío Computacional



### Variabilidad Visual

- Diversidad de síntomas, colores y severidades de enfermedades foliares



### Contexto Ambiental

- Análisis y correlación de factores como humedad, temperatura, radiación y precipitación



### Condiciones Cambiantes

- Algoritmo robusto a variabilidad estacional y cambios climáticos



### Escasez de Datos Etiquetados

- Limitada disponibilidad de imágenes etiquetadas
- Promueve prácticas agrícolas más sostenibles

# Análisis y Procesamiento



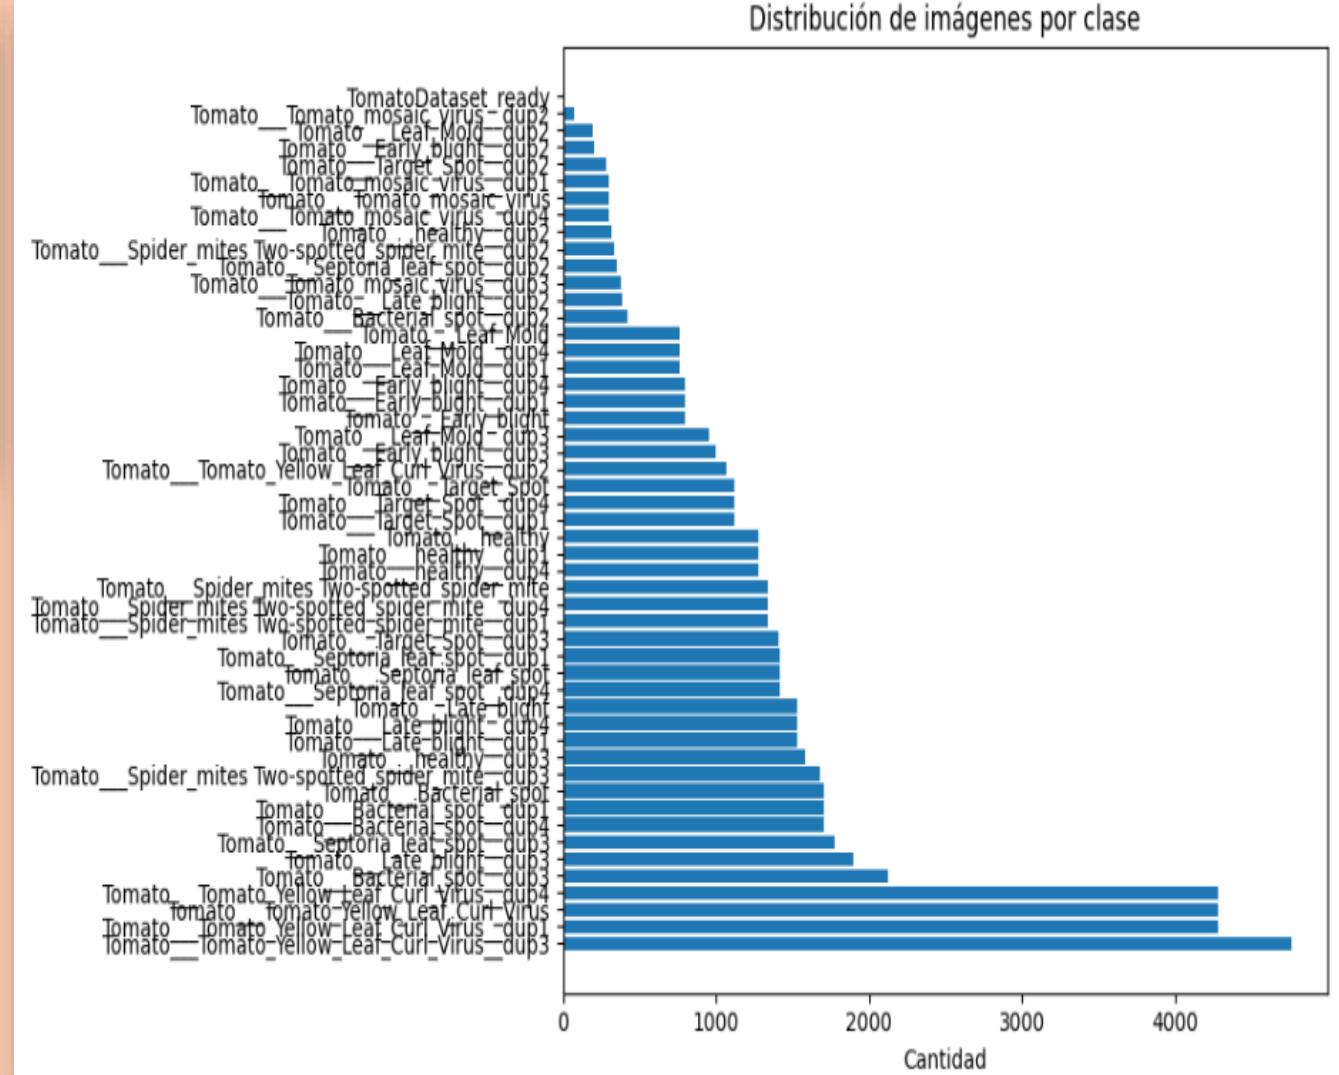
# Proceso

- Pipeline de Preparación de Datos.
- Validación del Dataset.
- Búsqueda de Clases.
- Construcción del Dataset.
- Eda del Dataset Tomato

# Visualizaciones

Resumen por clase:		
	Clase	Cantidad_imagenes
39	Tomato__Tomato_Yellow_Leaf_Curl_Virus_dup3	4761
37	Tomato__Tomato_Yellow_Leaf_Curl_Virus_dup1	4286
36	Tomato__Tomato_Yellow_Leaf_Curl_Virus	4286
40	Tomato__Tomato_Yellow_Leaf_Curl_Virus_dup4	4286
4	Tomato__Bacterial_spot_dup3	2126
14	Tomato__Late_blight_dup3	1897
24	Tomato__Septoria_leaf_spot_dup3	1771
5	Tomato__Bacterial_spot_dup4	1702
2	Tomato__Bacterial_spot_dup1	1702
1	Tomato__Bacterial_spot	1702
29	Tomato__Spider_mites Two-spotted_spider_mite_...	1676
49	Tomato__healthy_dup3	1585
12	Tomato__Late_blight_dup1	1527
15	Tomato__Late_blight_dup4	1527
11	Tomato__Late_blight	1527
25	Tomato__Septoria_leaf_spot_dup4	1417
21	Tomato__Septoria_leaf_spot	1417
22	Tomato__Septoria_leaf_spot_dup1	1417
34	Tomato__Target_Spot_dup3	1404
27	Tomato__Spider_mites Two-spotted_spider_mite_...	1341
30	Tomato__Spider_mites Two-spotted_spider_mite_...	1341
26	Tomato__Spider_mites Two-spotted_spider_mite	1341

Estadísticas de tamaño de imágenes:		
	Ancho	Alto
count	64761.0	64761.0
mean	256.0	256.0
std	0.0	0.0
min	256.0	256.0
25%	256.0	256.0
50%	256.0	256.0
75%	256.0	256.0
max	256.0	256.0



# Visualizaciones

Tomato\_\_Bacterial\_spot\_dup3



Tomato\_\_Late\_blight\_dup3



Tomato\_\_Septoria\_leaf\_spot\_d



Tomato\_\_Bacterial\_spot\_dup4



Tomato\_\_Bacterial\_spot\_dup1



Tomato\_\_Bacterial\_spot



Tomato\_\_Spider\_mites\_Two-spot



Tomato\_\_healthy\_dup3



Conclusiones automáticas:

- Total de clases: 51
- Total de imágenes: 64761
- Resolución promedio aproximada: 256 x 256
- Clases con menos imágenes:

	Clase	Cantidad_imagenes
18	Tomato__Leaf_Mold_dup2	191
43	Tomato__Tomato_mosaic_virus_dup2	74
0	TomatoDataset_ready	0

# Visualización

## RESUMEN GENERAL

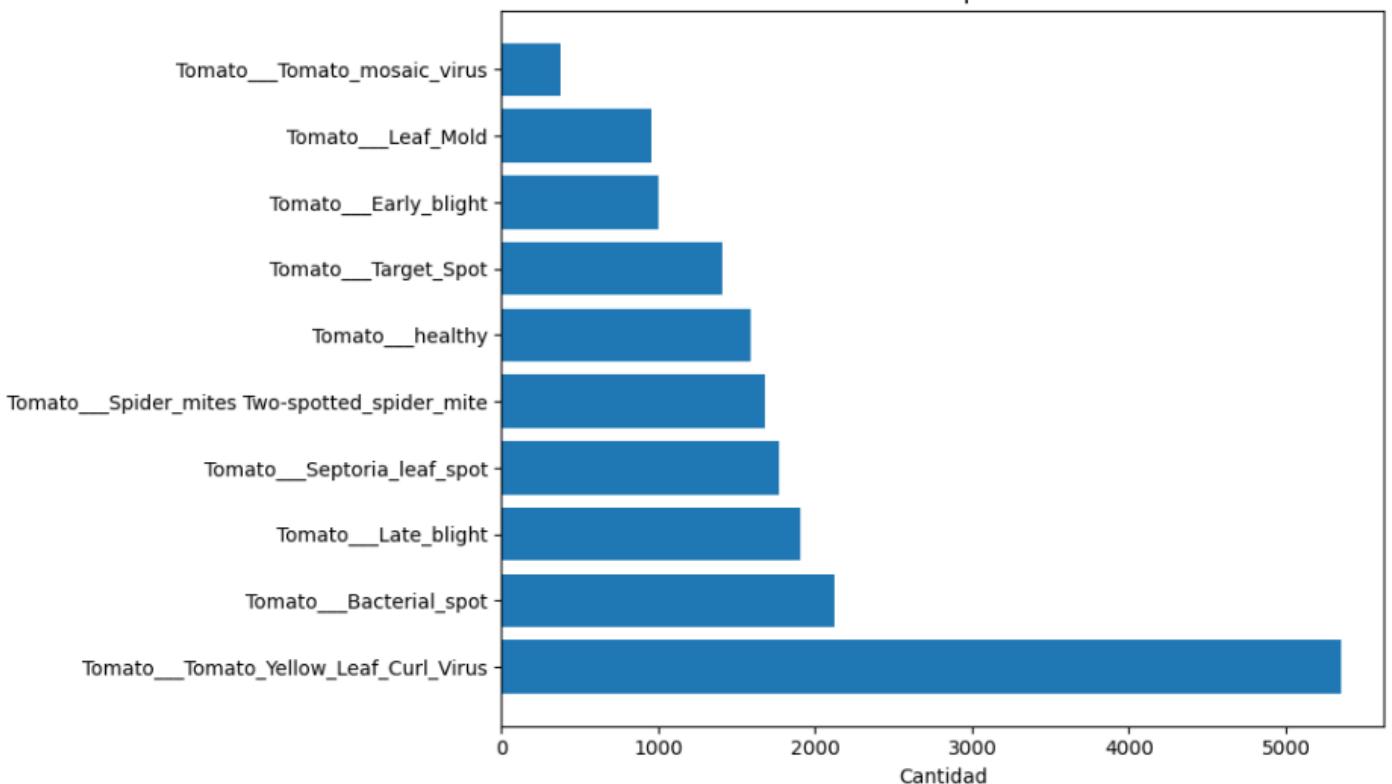
Total imágenes: 18146

Total clases: 10

Corruptas: 0

	Cantidad	Porcentaje
Clase		
Tomato__Tomato_Yellow_Leaf_Curl_Virus	5357	29.52
Tomato__Bacterial_spot	2127	11.72
Tomato__Late_blight	1901	10.48
Tomato__Septoria_leaf_spot	1771	9.76
Tomato__Spider_mites Two-spotted_spider_mite	1676	9.24
Tomato__healthy	1585	8.73
Tomato__Target_Spot	1404	7.74
Tomato__Early_blight	1000	5.51
Tomato__Leaf_Mold	952	5.25
Tomato__Tomato_mosaic_virus	373	2.06

Distribución por clase



# Visualización

ESTADÍSTICAS GLOBALES							
	Ancho	Alto	Aspect	Brillo	Contraste	Entropia	Blur
count	18146.0	18146.0	18146.0	18146.000000	18146.000000	18146.000000	18146.000000
mean	256.0	256.0	1.0	115.607121	38.163846	6.998742	4095.634562
std	0.0	0.0	0.0	16.330085	10.695764	0.517583	4434.449148
min	256.0	256.0	1.0	8.246216	10.629742	1.352320	5.019577
25%	256.0	256.0	1.0	106.267632	29.963157	6.764452	716.729044
50%	256.0	256.0	1.0	115.971916	38.307126	7.076588	2740.308527
75%	256.0	256.0	1.0	124.544544	46.177556	7.352979	6145.844635
max	256.0	256.0	1.0	194.555527	80.729056	7.791131	27109.052995

	Clase	Brillo	Contraste	Blur	Ancho	Alto
	Tomato__Bacterial_spot	104.92	33.41	1058.66	256.0	256.0
	Tomato__Early_blight	110.58	46.31	3025.38	256.0	256.0
	Tomato__Late_blight	113.61	39.63	2544.53	256.0	256.0
	Tomato__Leaf_Mold	115.41	36.82	3162.19	256.0	256.0
	Tomato__Septoria_leaf_spot	130.90	37.84	4766.69	256.0	256.0
	Tomato__Spider_mites Two-spotted_spider_mite	119.27	44.56	6781.24	256.0	256.0
	Tomato__Target_Spot	118.75	45.10	7209.69	256.0	256.0
	Tomato__Tomato_Yellow_Leaf_Curl_Virus	114.20	34.71	1797.99	256.0	256.0
	Tomato__Tomato_mosaic_virus	117.35	34.79	6142.23	256.0	256.0
	Tomato__healthy	116.24	38.34	12203.31	256.0	256.0

## mediante Deep Learning e IoT

### Datos Entrenamiento



### Estrategias Sistemáticas



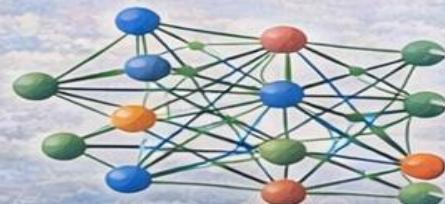
### Estrategias Sistemáticas



### Q Grid Search Cross Validation

		Testing			
		16	32	32	64
Learning Rate		1	1	1	1
0.001	0.001	1	✓	✓	✓
0.01	0.01	1	1	1	✓
0.1	1.1	1	1	1	1

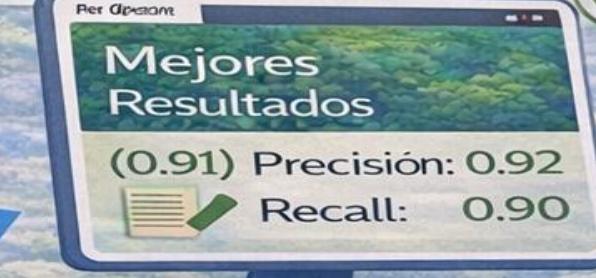
### Modelo Seleccionado



### Evaluación Final y Resultados

Mejores Resultados Encontrados:

(0.91) Precisión: 0.92  
Recall: 0.90



### Entrenamiento, Ajuste y Evaluación de Modelos de Aprendizaje Supervisado

Selección sistemática de hiperparámetros utilizando Grid Search, Cross Validation y estrategias sistemáticas

# Modelo de KNN



# Modelo de KNN

- **KNN para Enfermedades del Tomate**
  - **Clasificación por similitud:** la hoja se etiqueta según sus **K hojas más cercanas** en el espacio de características.
  - **Datos de entrada:** imágenes foliares convertidas en **features o embeddings** (color, textura o CNN).
  - **Uso en el proyecto:** modelo base explicable para detectar **hojas sanas vs enfermas** y tipos de enfermedad.

# Modelo KNN

- Clasificación perfecta en test (**Accuracy = 1.00, F1-macro = 1.00**).
- **Recall = 1.00**: no se omiten casos reales de enfermedad.
- **Precision = 1.00**: sin falsas alarmas.
- Enfoque **simple, confiable y efectivo** para detección temprana en contextos rurales (Chiloé).

# Modelos de RF



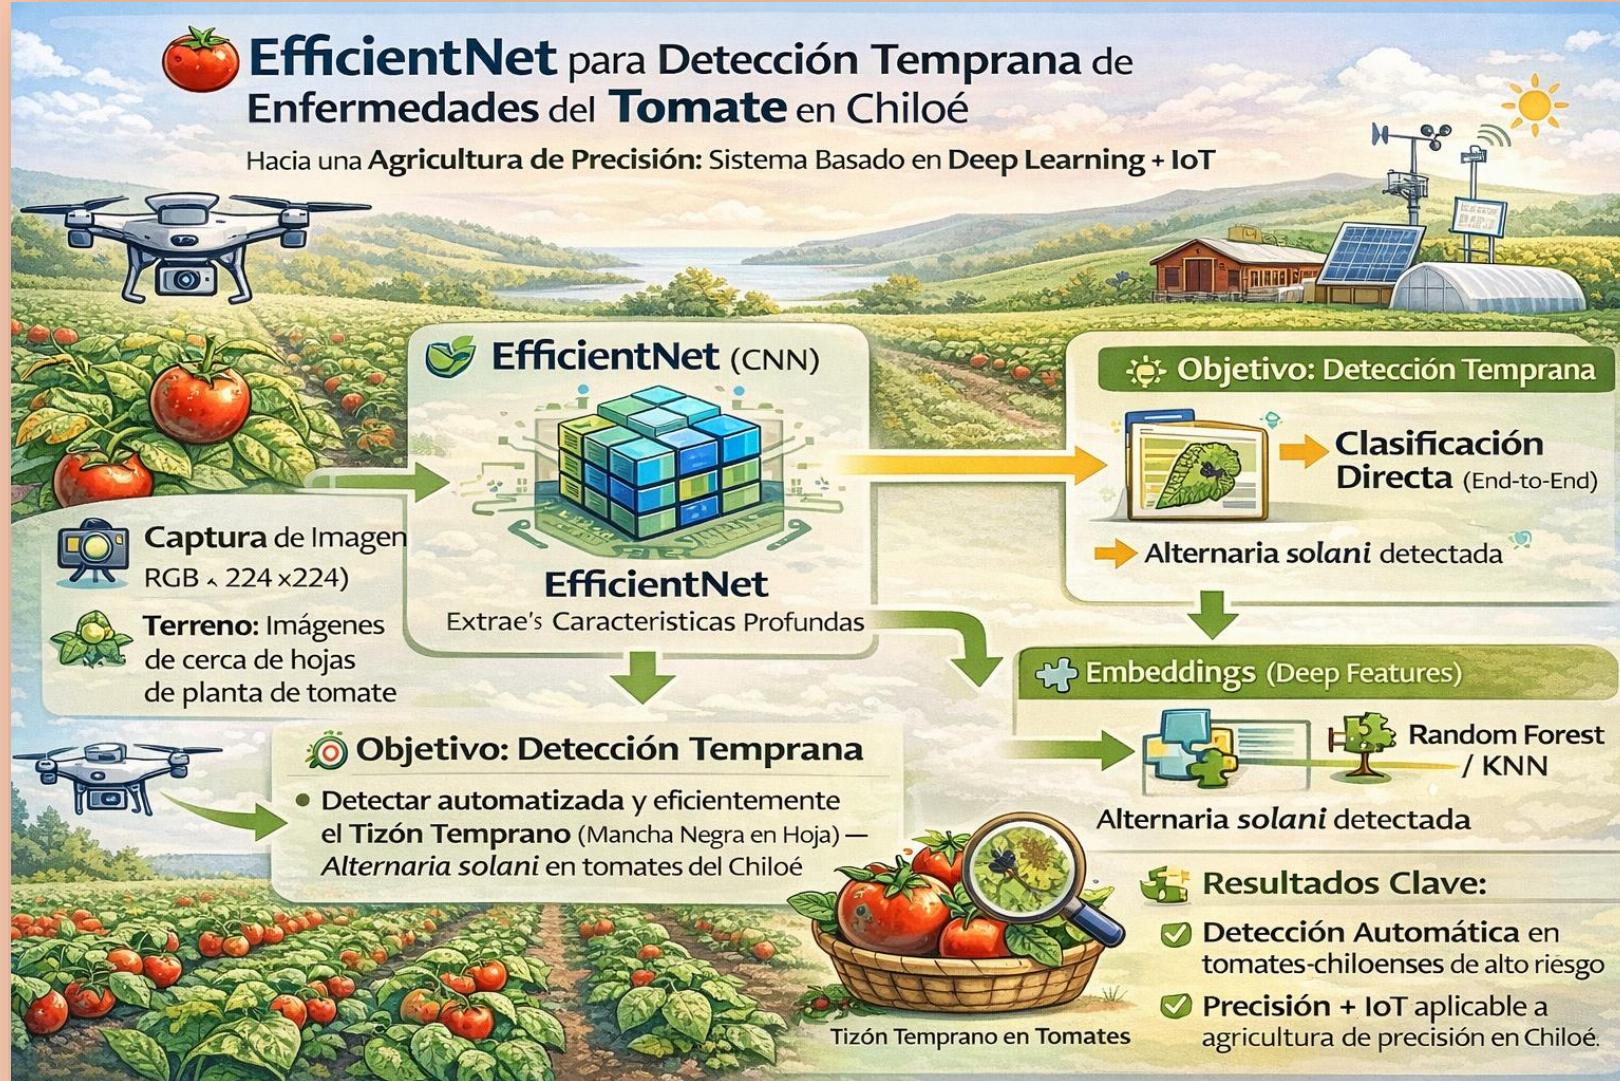
# Modelo RF

- **Random Forest para Enfermedades del Tomate**
  - **Ensamble de árboles** → decisión por votación.
  - **Entrada:** *features / embeddings* de hojas.
  - **Robusto y estable** → menos sobreajuste, buen rendimiento multiclas.

# Modelo de RF

- **Buen equilibrio desempeño–eficiencia:** Accuracy  $\approx 0.85$ , F1-macro  $\approx 0.80$ .
- **Alta discriminación** en enfermedades con patrones claros (Precision/Recall  $> 0.90$ ).
- **Limitaciones** en clases visualmente similares (menor recall).
- **Ventaja clave:** modelo robusto, interpretable y apto para despliegue IoT/Edge.

# Modelo de EfficientNet



# Modelos de EfficientNet

- **EfficientNet para Enfermedades del Tomate**
  - **Captura en campo (dron/terreno)**: imágenes RGB de hojas de tomate → entrada al sistema.
  - **EfficientNet (CNN)**: extrae **Deep features** y permite **clasificación directa o embeddings + RF/KNN**.
  - **Resultado: detección temprana** de enfermedades del tomate (p. ej., tizón temprano) para agricultura de precisión en Chiloé.

# Modelos de EfficientNet

- Mejor desempeño global ( $Accuracy \approx 0.92$ ,  $F1\text{-macro} \approx 0.91$ ).
- Alta capacidad de generalización en escenarios multiclase desbalanceados.
- $Recall$  elevado en enfermedades críticas → detección temprana confiable.
- Limitaciones solo en clases visualmente muy similares.

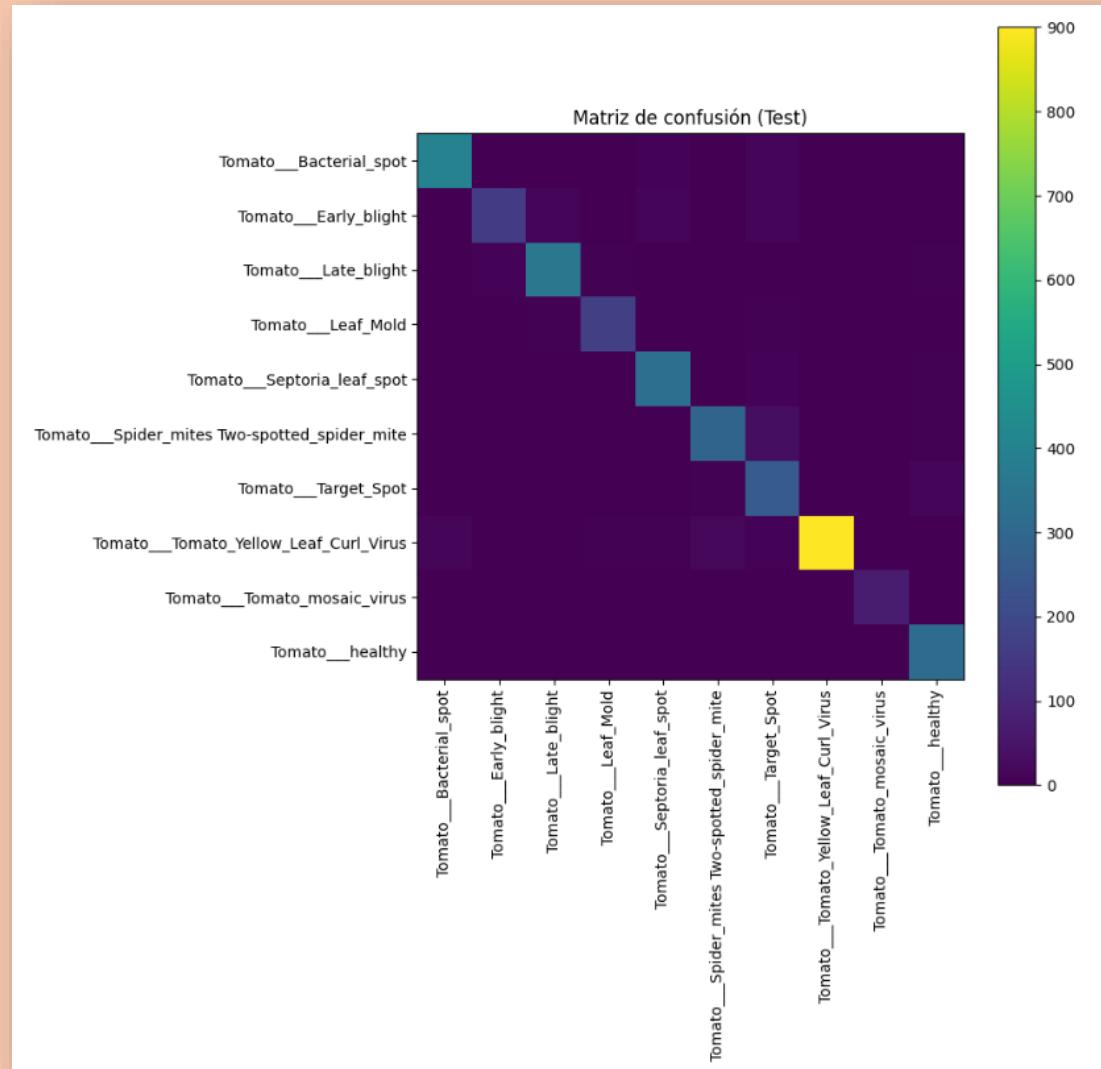
# Visualizaciones

```
Test loss: 0.2398664355278015  
Test accuracy: 0.9244799017906189  
Macro F1: 0.9103535555182836
```

Reporte de clasificación:

		precision	recall	f1-score	support
	Tomato__Bacterial_spot	0.96	0.94	0.95	425
	Tomato__Early_blight	0.92	0.78	0.84	200
	Tomato__Late_blight	0.94	0.94	0.94	380
	Tomato__Leaf_Mold	0.91	0.90	0.90	190
	Tomato__Septoria_leaf_spot	0.90	0.93	0.92	354
Tomato__Spider_mites	Two-spotted_spider_mite	0.90	0.87	0.88	335
	Tomato__Target_Spot	0.75	0.92	0.83	281
Tomato__Tomato_Yellow_Leaf_Curl_Virus		1.00	0.95	0.97	952
	Tomato__Tomato_mosaic_virus	0.94	0.91	0.93	75
	Tomato__healthy	0.90	0.99	0.94	317
	accuracy			0.92	3509
	macro avg	0.91	0.91	0.91	3509
	weighted avg	0.93	0.92	0.93	3509

# Visualizaciones



# Visualizaciones

Elegir archivos Ningún archivo seleccionado Upload widget is only available when the cell has been executed in the current browser session. Please rerun this cell to enable.  
Saving 0a9b3ff4-5343-4814-ac2c-fdb3613d4e4d\_\_Crn1\_L.Mold 6559.JPG to 0a9b3ff4-5343-4814-ac2c-fdb3613d4e4d\_\_Crn1\_L.Mold 6559.JPG  
Imagen cargada: 0a9b3ff4-5343-4814-ac2c-fdb3613d4e4d\_\_Crn1\_L.Mold 6559.JPG

Imagen subida



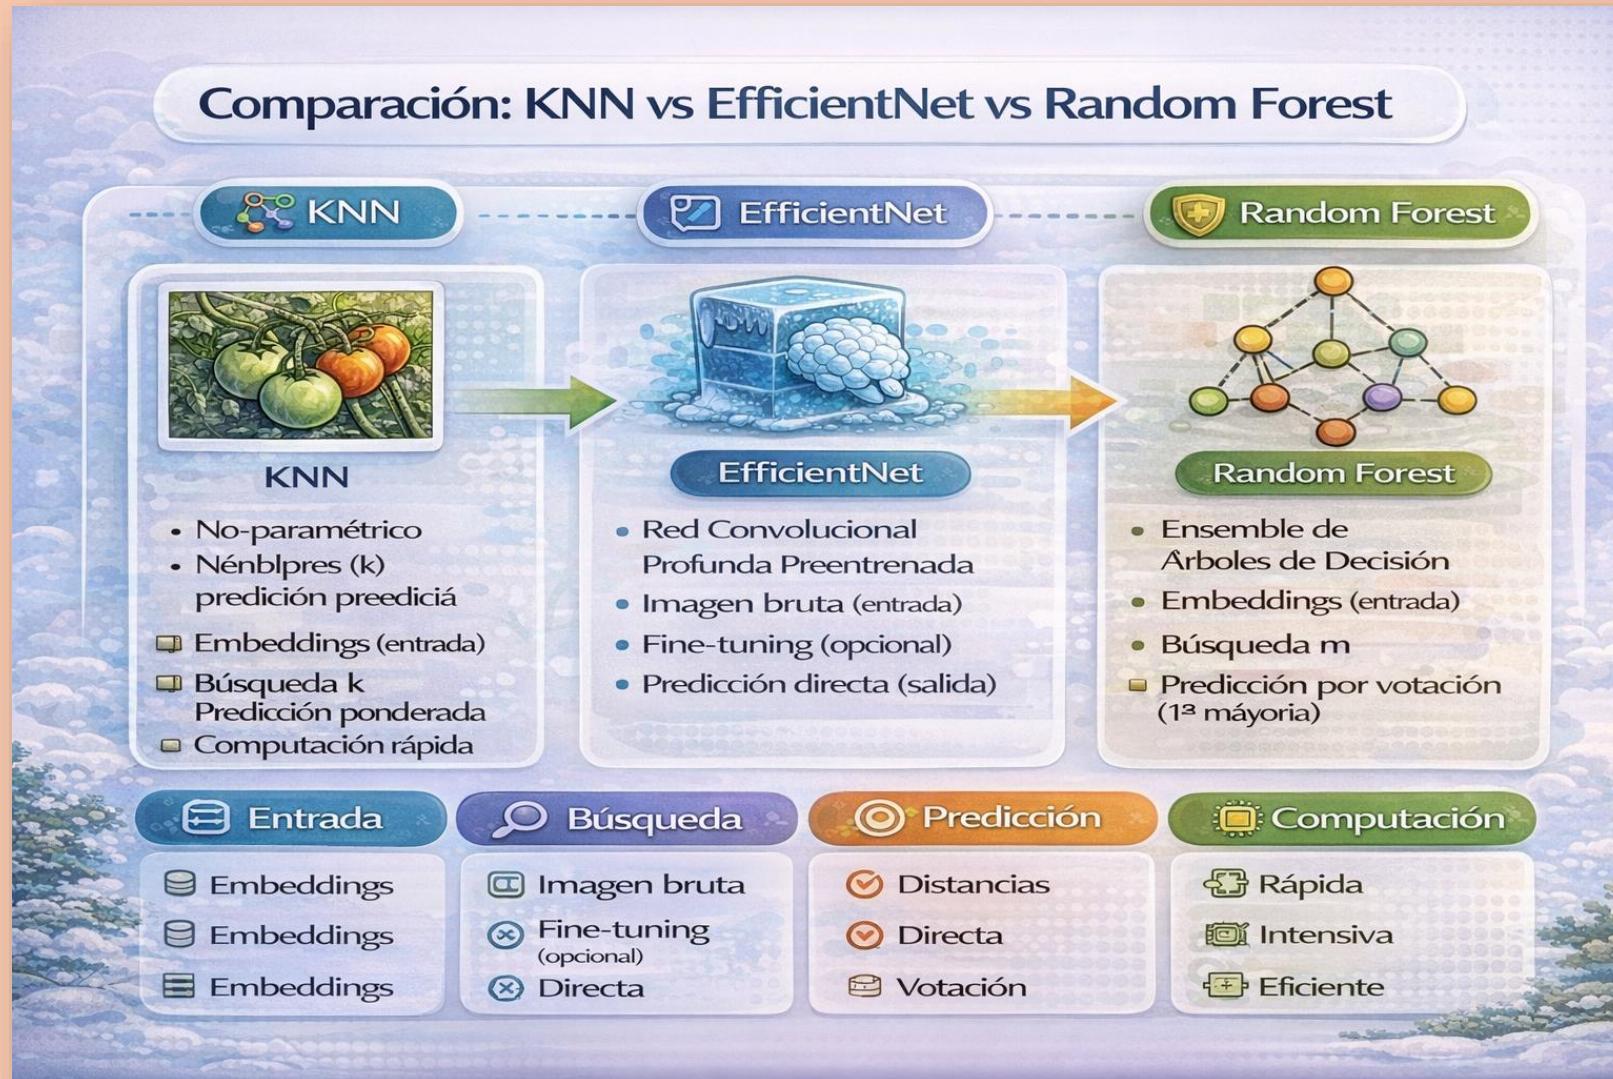
Predicción: Tomato\_\_Leaf\_Mold

Confianza (prob): 0.9899

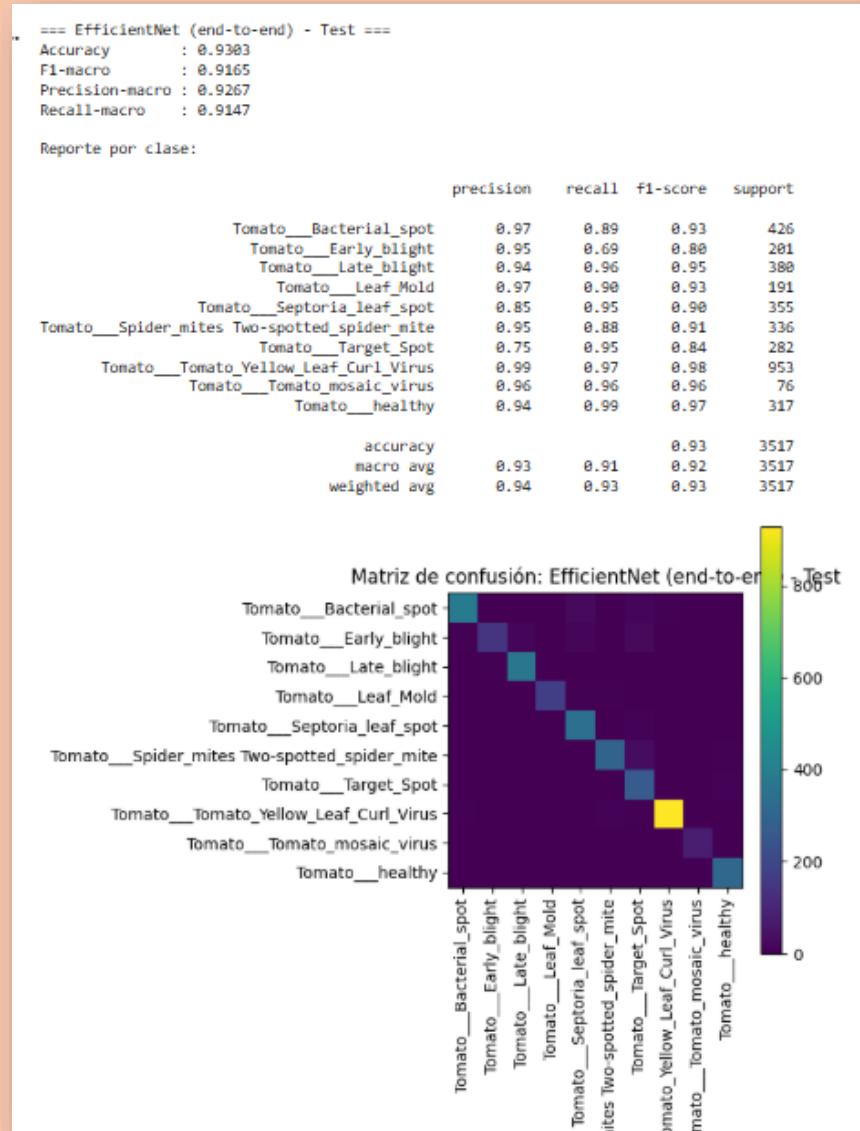
Top 5 predicciones:

- Tomato\_\_Leaf\_Mold prob=0.9899
- Tomato\_\_Late\_blight prob=0.0039
- Tomato\_\_Tomato\_Yellow\_Leaf\_Curl\_Virus prob=0.0021
- Tomato\_\_Spider\_mites Two-spotted\_spider\_mite prob=0.0014
- Tomato\_\_Early\_blight prob=0.0012

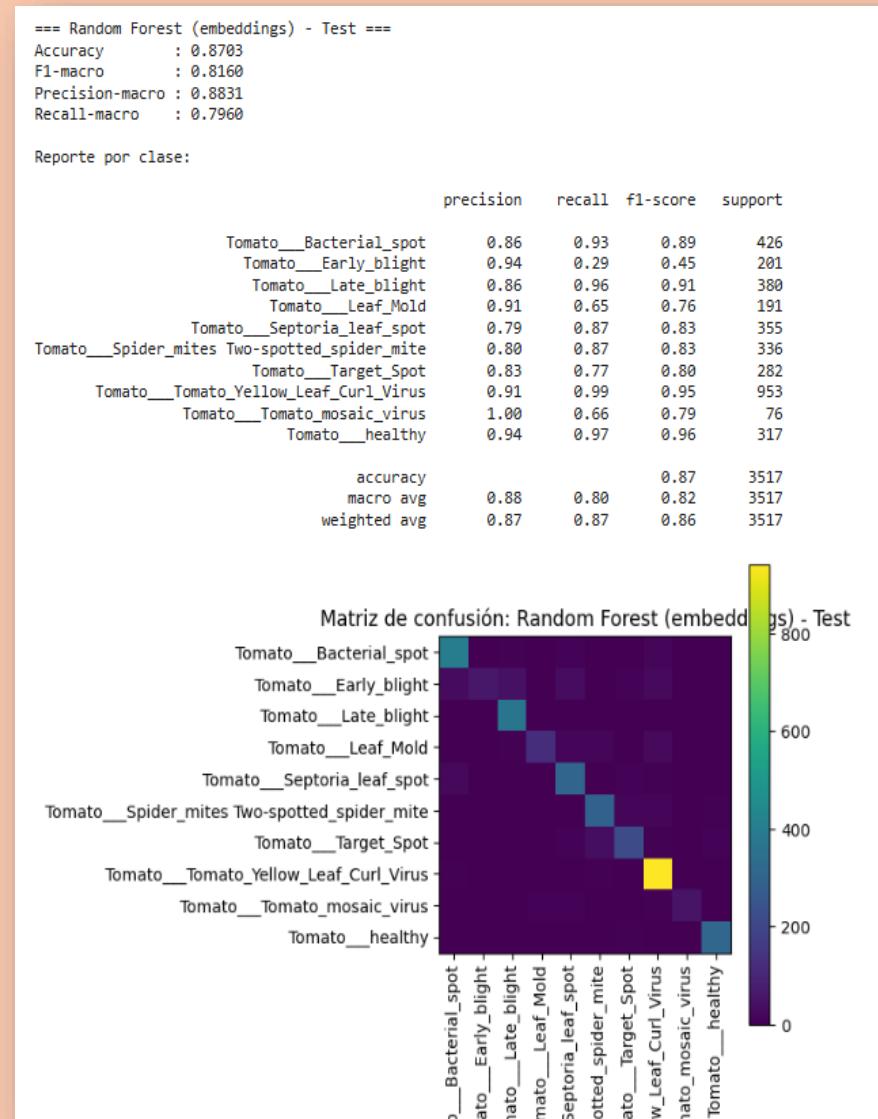
# Proceso de Comparación 3 Modelos



# Visualizaciones



# Visualizaciones



# Visualizaciones

Imagen cargada: septoria\_leaf.JPG



```
== EfficientNet (end-to-end) ==
Predicción: Tomato__Septoria_leaf_spot
Top-5:
- Tomato__Septoria_leaf_spot: 0.9951
- Tomato__Tomato_mosaic_virus: 0.0023
- Tomato__Target_Spot: 0.0022
- Tomato__Bacterial_spot: 0.0002
- Tomato__Leaf_Mold: 0.0001

== KNN (embeddings) ==
Predicción: Tomato__Septoria_leaf_spot
Top-5:
- Tomato__Septoria_leaf_spot: 1.0000
- Tomato__healthy: 0.0000
- Tomato__Tomato_mosaic_virus: 0.0000
- Tomato__Tomato_Yellow_Leaf_Curl_Virus: 0.0000
- Tomato__Target_Spot: 0.0000

== Random Forest (embeddings) ==
Predicción: Tomato__Septoria_leaf_spot
Top-5:
- Tomato__Septoria_leaf_spot: 0.5685
- Tomato__Target_Spot: 0.1051
- Tomato__healthy: 0.0676
- Tomato__Bacterial_spot: 0.0605
- Tomato__Late_blight: 0.0452
```

# Evaluación Comparativa de Modelos

- **EfficientNet end-to-end:** mejor desempeño global ( $\text{Acc} \approx 0.93$ ,  $\text{F1-macro} \approx 0.91$ ), alta generalización y bajo riesgo de omisión.
- **KNN sobre embeddings:** buen rendimiento general ( $\text{Acc} \approx 0.90$ ), pero sensible a clases visualmente similares.
- **Random Forest sobre embeddings:** menor desempeño ( $\text{Acc} \approx 0.87$ ), limitado por bajo recall en clases críticas.
- **Conclusión:** EfficientNet es la opción más robusta para alerta temprana; embeddings son viables cuando se prioriza eficiencia computacional.

# Comparación de Modelos

## Comparación de Modelos – Enfermedades Foliares del Tomate

**EfficientNet (Deep Learning):**

- Máxima precisión y mejor detección de enfermedades complejas, a costa de **mayor tiempo de entrenamiento** e inferencia.

**Random Forest (embeddings):**

- Mejor balance entre desempeño y eficiencia; buen F1-macro con baja latencia, ideal para despliegue práctico.

**KNN (embeddings):**

- Modelo simple y rápido de entrenar; útil como referencia, pero menos robusto frente a clases similares.

# Análisis Crítico de Resultados y Despliegue del Modelo

## Detección Temprana de Enfermedades Foliares mediante Deep Learning e IoT

Enfoque Integral  
y Aplicación Real



# Análisis Crítico del Modelo

- *Deep Learning + IoT* es una estrategia efectiva para la **detección temprana** de enfermedades foliares en Chiloé.
- *EfficientNet end-to-end* ofrece el **mejor desempeño diagnóstico**, ideal para análisis centralizados.
- *Random Forest* sobre **embeddings** logra el **mejor equilibrio entre precisión y eficiencia**, apto para **IoT/Edge**.
- **Altos valores de *recall* y *precision*** reducen omisiones y falsas alarmas, habilitando decisiones agronómicas oportunas y escalables.

# Detección Temprana de Enfermedades Foliares mediante Deep Learning e IoT

